

NLP y embeddings

Laboratorio 7 · Ian Cumes · carné 23236 · entrega individual

Investigación y preprocesamiento

Se implementó SGNS propio y se comparó con gensim y GloVe en analogías, similitud léxica y clasificación AG News. El mejor clasificador observado con todos los datos fue sgns_finetune, con F1 macro 92.10% en test. El notebook conserva resultados extensos, código comentado y manifiestos reproducibles.

CBOW predice el centro desde el contexto; Skip-Gram predice contexto desde el centro. Negative sampling discrimina pares reales frente a ruido unigram elevado a 0.75. GloVe ajusta productos de vectores a logaritmos de coocurrencias globales ponderadas. Los dos métodos capturan relaciones distribucionales, pero asignan un único vector por palabra y pueden reproducir sesgos.

nn.Embedding representa una tabla $V \times d$. from_pretrained permite inicialización y congelamiento. EmbeddingBag reduce cada documento por mean, sum o max; offsets indica comienzos dentro de IDs concatenados. Aquí se usa mean, padding_idx=0 y una bolsa por noticia.

El tokenizador propio usa minúsculas, palabras Unicode, apóstrofes internos, números y puntuación; repara marcadores @ y elimina especiales y signos de encabezados. Se comparó con NLTK Treebank en 12 oraciones: las contracciones y posesivos explican diferencias. No se aplicó stemming ni eliminación de stopwords.

Split	Artículos	Líneas	Tokens normalizados
train	29 443	1 801 350	102 356 963
validation	60	3 760	216 023
test	62	4 358	242 994

Se seleccionaron 5 886 artículos completos del entrenamiento, con semilla 23236, hasta 20 000 727 tokens. Los corpus 25/50/100% son prefijos anidados que terminan en artículos completos. Zipf: los top 10/1000/30000 cubren 28.69%/69.80%/96.26% de tokens.

min_count	Vocabulario seleccionado	Tokens excluidos
1	211 559	0.00%
5	72 216	1.14%
10	49 323	1.89%

La preparación preserva fronteras de línea y bloques de hasta 1000 tokens. Gensim y SGNS reciben el mismo archivo de tokens elegibles, comprobado por hash y vocabulario. Los especiales y palabras bajo min_count no generan pares de entrenamiento.

Entrenamiento y selección

El SGNS propio usa dos tablas nn.Embedding dispersas. Minimiza $-\log \sigma(v \cdot u) - \sum \log \sigma(-v \cdot n)$, preservando los vectores de entrada. Genera pares por bloques, sin cruzar contextos; rechaza negativos iguales al contexto positivo. La suma del minibatch guía SGD y la pérdida publicada se promedia por par.

Cada configuración tiene tres epochs, minibatch de 4096 pares, min_count=5, subsampling $t=10^{-4}$ y SGD con learning rate lineal $0.025 \rightarrow 0.0001$. La ventana es fija. Se guardan checkpoint, pérdida, analogías semánticas/sintácticas, WordSim, vecinos de seis palabras, tiempos y memoria por epoch. La selección usa WordSim sin redondear sobre pares comunes y accuracy de analogías como desempate; SimLex queda reservado.

Configuración	d/w/k	Tokens corpus	Epoch	p WordSim	Acc analogías	Min total
base100	100/5/5	20 000 727	3	0.64609	27.67%	7.7
dim50	50/5/5	20 000 727	3	0.62422	22.48%	7.6
dim300	300/5/5	20 000 727	3	0.63519	27.27%	7.5
corpus25	100/5/5	5 005 631	3	0.53328	8.00%	1.6
corpus50	100/5/5	10 007 877	3	0.59154	17.23%	3.2
window2	100/2/5	20 000 727	3	0.57344	24.32%	2.7
negative10	100/5/10	20 000 727	3	0.64603	30.05%	9.9

Selección: base100, epoch 3, p WordSim=0.64609. En la base, el subsampling redujo 191 078 458 pares a 99 965 588 en la primera epoch; conservó 10 599 920 tokens elegibles. La pérdida media base pasó de 2.263 a 2.240.

El descarte observado de the/of/and en la primera epoch fue the: 95.89%, of: 93.55%, and: 93.27%.

Hardware medido: Tesla T4, PyTorch 2.8.0+cu126, Python 3.12.12; tiempo SGNS acumulado de las siete configuraciones 40.2 minutos. La memoria GPU máxima asignada a tensores durante entrenamiento fue 242.9 MiB. Estos tiempos excluyen descarga y evaluación.

Gensim se entrenó en CPU Intel(R) Xeon(R) CPU @ 2.00GHz con cuatro workers, el mismo corpus/vocabulario y parámetros equivalentes. Sus actualizaciones Cython asíncronas difieren de los minibatches; descarta colisiones de negativos en vez de redibujarlas. Se registra cada epoch, sin exigir vectores numéricamente iguales.

GloVe es exactamente glove-wiki-gigaword-100: 400000 palabras, 100d y 6 mil millones de tokens. El artículo informa dos Intel Xeon E5-2658 de 2.1 GHz, 85 min de coocurrencias en un hilo y 14 min por iteración de 300d en 32 cores. Son mediciones publicadas de otra dimensión; aquí no se entrenó GloVe.

Aritmética vectorial y geometría

analogia(a,b,c,k) implementa 3CosAdd con vectores individuales normalizados y búsqueda por coseno de $b-a+c$. Se excluyen las consultas a/b/c y se verificó coincidencia de top-5 y similitudes con gensim. 3CosMul usa el cociente de productos de cosenos desplazados a $[0,1]$, con $\epsilon=10^{-6}$. Las consultas excluidas impiden respuestas triviales.

Los tres embeddings se evalúan sobre las mismas 12 227 preguntas cubiertas de 19 544, en 14 categorías, con exactamente 30000 candidatos compartidos: cobertura 62.56%. Accuracy usa solo preguntas cubiertas; la cobertura debe acompañarla. Los resultados por categoría están en el notebook.

Modelo	Sem. Add/Mul %	Sint. Add/Mul %	Total Add	Total Mul	Paralelismo
sgns	21.24/19.87	31.48/29.08	28.24%	26.16%	0.44716
gensim	22.27/20.80	31.83/29.57	28.81%	26.79%	0.45638
glove	60.36/57.29	67.23/65.85	65.05%	63.14%	0.59617

Se probaron 18 analogías personales de seis tipos, con top-5, similitudes, rango correcto, OOV y búsqueda con/sin exclusión. Ejemplos observados:

Modelo	Resultado	Consulta	Esperado	Top 1	Rango
sgns	Acierto	sister – brother + uncle	aunt	aunt	1
gensim	Acierto	paris – france + germany	berlin	berlin	1
glove	Acierto	woman – man + king	queen	queen	1

Categoría	SGNS Add/Mul %	Gensim Add/Mul %	GloVe Add/Mul %
Capitales comunes	32.9/31.2	35.1/34.2	94.4/92.4
Capitales mundo	19.0/17.9	19.9/19.1	87.4/83.8
Monedas	0.0/0.0	0.0/0.0	5.7/8.6
Ciudades/estados	15.4/13.9	16.7/14.7	28.7/25.1
Familia	47.7/46.5	46.8/44.2	88.3/87.4
Adj. → adverbio	4.6/3.8	5.7/4.7	28.1/28.2
Opuestos	6.5/3.9	6.5/3.3	28.8/24.8
Comparativos	35.2/31.6	36.5/34.3	80.4/78.0
Superlativos	19.5/20.4	19.4/19.7	61.3/62.4
Gerundios	23.8/19.4	22.6/18.4	73.1/72.2
Gentilicios	62.4/62.5	61.4/60.1	97.3/95.8
Pasado	39.9/35.8	42.4/38.7	55.9/53.6
Plurales	28.7/23.9	28.5/24.7	79.1/74.8
Verbos plurales	17.9/16.7	16.8/16.4	58.5/60.6

En SGNS, woman–man+king coloca queen en rango 110 (coseno 0.599); sin exclusión, gana king. El $\approx$ no es una igualdad. El coseno entre $b-a$ y $d-c$ mide paralelismo sin garantizar el ranking. El notebook incluye t-SNE de 500 palabras por modelo: temas predefinidos, coseno, perplexity 30, 1500 iteraciones y semilla 23236; sus ejes y distancias globales no son medidas semánticas.

Clasificación de noticias

AG News se separó en 108000 ejemplos de entrenamiento y 12000 de validación estratificada, sin solapamiento de índices; test oficial contiene 7600. Las fracciones 1/10/50/100% usan 1080/10800/54000/108000 ejemplos anidados por clase. Cada vocabulario y TF-IDF se aprende únicamente desde la fracción correspondiente.

TF-IDF usa unigramas/bigramas, min_df=2 y hasta 100000 características; regresión logística L2 con optimización SGD. Todos los modelos neuronales usan EmbeddingBag(mean) → MLP de 128 unidades, ReLU, dropout 0.2 y salida de cuatro clases. Adam 0.001, batch 512, máximo 10 epochs y parada tras dos epochs sin mejorar F1 macro.

La inicialización aleatoria tiene 100d. SGNS, gensim y GloVe se comparan congelados y ajustables, adaptando solo la entrada a su dimensión. Los OOV preentrenados parten de cero; congelados no aportan señal léxica y ajustables pueden aprender. Validación fija variante y checkpoint antes de evaluar test; se guardan hashes, predicciones y matrices.

Fracción	TF-IDF	Aleatorio	SGNS	Gensim	GloVe
1%	81.94%	31.20%	71.89%	80.68%	66.73%
10%	89.28%	88.75%	89.19%	89.03%	89.23%
50%	91.36%	91.62%	91.53%	91.58%	91.52%
100%	91.61%	92.10%	92.10%	92.03%	92.08%

F1 macro en test por fracción. Cada columna usa la variante elegida exclusivamente con validación para esa fracción; no se cambió la selección después de ver test.

Modelo al 100%	Acc	P macro	R macro	F1 macro	Par entrenables	Min
tfidf	91.63%	91.62%	91.63%	91.61%	400 004	0.7
random	92.11%	92.11%	92.11%	92.10%	4 383 644	0.1
sgns_finetime	92.11%	92.12%	92.11%	92.10%	4 383 644	0.1
gensim_finetime	92.04%	92.06%	92.04%	92.03%	4 383 644	0.1
glove_finetime	92.09%	92.09%	92.09%	92.08%	4 383 644	0.1

El mayor F1 al 100% fue sgns_finetime (92.10%), apenas 0.0020 puntos sobre random; no se estima significancia. La matriz con más errores fue tfidf; su mayor confusión dirigida fue Business→Sci/Tech (155 ejemplos). Las veinte matrices y curvas están guardadas en el notebook y archivos JSON/CSV.

Los embeddings congelados exigen menos parámetros entrenables; fine-tuning adapta dominio y OOV, pero requiere etiquetas. La referencia TF-IDF puede competir bien en noticias por su señal léxica y bigramas. La ventaja observada con poco entrenamiento se interpreta en la siguiente página, sin atribuir causalidad a una única semilla.

Conclusiones y referencias

Modelo	d	Vocab	ρ WS	Cob WS	ρ SL	Cob SL	F1 test	Min entren
sgns	100	72 216	0.64358	98.87%	0.28274	99.60%	92.10%	7.7
gensim	100	72 216	0.63491	98.87%	0.28432	99.60%	92.03%	5.7
glove	100	400 000	0.53274	100.00%	0.29755	100.00%	92.08%	Externo

WS=WordSim-353; SL=SimLex-999. Las correlaciones finales usan pares cubiertos por cada vocabulario, por lo que se muestra cobertura. SimLex se evaluó después de cerrar la selección de embeddings. Los tiempos de SGNS/gensim suman tres epochs de la configuración comparada, sin descarga ni evaluación.

OOV de tokens en test AG News: sgns 3.32%, gensim 3.32%, glove 0.88%. SGNS y gensim usan 20 000 727 tokens normalizados; GloVe usa 6000000000. El hardware medido y el publicado se distinguen en la página 2.

La configuración SGNS elegida fue base100 en epoch 3. glove obtuvo la mayor correlación SimLex observada. La tabla muestra que calidad intrínseca y F1 de clasificación deben examinarse por separado: son tareas con objetivos y distribuciones distintos.

Con 1% de etiquetas, GloVe obtuvo F1 66.73% frente a 31.20% del embedding aleatorio: +35.53 puntos. TF-IDF fue superior a ambos (81.94%). Validación eligió fine-tuning para los tres preentrenados en todas las fracciones; el beneficio depende de datos y tarea.

A epoch 3, 50/300d no superaron la base en WordSim; ventana 2 obtuvo 0.57344. Diez negativos casi empataron (0.64603) con más costo. Aumentar corpus 25→100% elevó accuracy de 8.00% a 27.67%. GloVe dispone de muchos más tokens; no se aísla causalmente el efecto del método.

Limitaciones: tres epochs, una semilla, sin intervalos de confianza; embeddings estáticos y promedio sin orden ni negación; tokenización y cobertura diferentes. Futuro: varias semillas, más entrenamiento y modelos sensibles al contexto.

Verificación: pérdida y gradientes contra entropía cruzada binaria, fronteras de contexto, exclusión de consultas y coincidencia con gensim; corpus mínimo y hashes, subconjuntos anidados, selección bloqueada y una evaluación test por modelo. El notebook se ejecutó desde kernel limpio. Los checkpoints y registros reales se recuperaron de Colab.

Referencias

Mikolov et al. (2013). Distributed Representations of Words and Phrases and their Compositionality. NeurIPS.
 Pennington, Socher y Manning (2014). GloVe: Global Vectors for Word Representation. EMNLP.
<https://nlp.stanford.edu/pubs/glove.pdf>

PyTorch 2.8: Embedding y EmbeddingBag. Gensim 4.4: Word2Vec y KeyedVectors. Fuentes de datos: Salesforce/WikiText-103 raw y fancyzhx/AG News en Hugging Face; WordSim-353, SimLex-999 y analogías en los recursos de gensim.

Entregables: notebook comentado, PDF, Word editable, código y dependencias, métricas, figuras, predicciones y mejores vectores SGNS .kv en la release v1.0-lab7.

Repositorio de la entrega: <https://github.com/iancumes/Lab7DeepLearning>